

1. Databázu údajov a ich zdroj.

Databázu som stiahla zo stránky kaggle.com. Dataset obsahuje 5 premenných a to:

- Rocne_vydavky - Suma, ktorú zákazník ročne utratí (v dolároch).
- Dlzka_clenstva - Dĺžka členstva zákazníka (v rokoch).
- Priemerny_cas_relacie - Priemerná dĺžka jednej návštevy (v minútach).
- Cas_straveny_na_aplikacii - Čas strávený na mobilnej aplikácii (v minútach).
- Cas_straveny_na_webstranke - Čas strávený na webovej stránke (v minútach).

2. Odhad úplnej kovariančnej a korelačnej matice.

Covariance Matrix, DF = 499			
	Rocne_vydavky	Dlzka_clenstva	Priemerny_cas_relacie
Rocne_vydavky	6290.834572	64.125922	27.954300
Dlzka_clenstva	64.125922	0.998556	0.059756
Priemerny_cas_relacie	27.954300	0.059756	0.985182
Cas_straveny_na_aplikacii	39.374988	0.028953	-0.027459
Cas_straveny_na_webstranke	-0.211655	-0.048046	-0.035091

Covariance Matrix, DF = 499		
	Cas_straveny_na_aplikacii	Cas_straveny_na_webstranke
Rocne_vydavky	39.374988	-0.211655
Dlzka_clenstva	0.028953	-0.048046
Priemerny_cas_relacie	-0.027459	-0.035091
Cas_straveny_na_aplikacii	0.988465	0.082771
Cas_straveny_na_webstranke	0.082771	1.021088

Kovariančná matica ukazuje, ako spolu súvisia dve premenné, a to pomocou kovariancií. Na hlavnej diagonále sa nachádzajú rozptyly (variance) jednotlivých premenných. Hodnoty mimo hlavnej diagonály sú kovariancie medzi dvojicami premenných.

Hodnota Ročných výdavkov (6290.834) nám hovorí o tom, že majú najväčšiu variabilitu zo všetkých premenných. Ostatné premenné majú rozptyl okolo hodnoty jeden, čo naznačuje, že väčšina hodnôt je blízko priemeru.

Najsilnejšie pozitívne vzťahy sú medzi Ročnými výdavkami a Dĺžkou členstva, Ročnými výdavkami a Priemerným časom relácie, Ročnými výdavkami a Časom stráveným na aplikácii.

Pearson Correlation Coefficients, N = 500 Prob > r under H0: Rho=0			
	Rocne_vydavky	Dlзка_clenstva	Priemerny_cas_relacie
Rocne_vydavky	1.00000	0.80908 <.0001	0.35509 <.0001
Dlзка_clenstva	0.80908 <.0001	1.00000	0.06025 0.1786
Priemerny_cas_relacie	0.35509 <.0001	0.06025 0.1786	1.00000
Cas_straveny_na_aplikacii	0.49933 <.0001	0.02914 0.5156	-0.02783 0.5348
Cas_straveny_na_webstranke	-0.00264 0.9530	-0.04758 0.2883	-0.03499 0.4350

Pearson Correlation Coefficients, N = 500 Prob > r under H0: Rho=0		
	Cas_straveny_na_aplikacii	Cas_straveny_na_webstranke
Rocne_vydavky	0.49933 <.0001	-0.00264 0.9530
Dlзка_clenstva	0.02914 0.5156	-0.04758 0.2883
Priemerny_cas_relacie	-0.02783 0.5348	-0.03499 0.4350
Cas_straveny_na_aplikacii	1.00000	0.08239 0.0657
Cas_straveny_na_webstranke	0.08239 0.0657	1.00000

Z korelačnej matice vidíme, že premenné Dĺžka členstva a Ročné výdavky zákazníka) sú silne pozitívne korelované (0.809). To znamená, že zákazníci s dlhším členstvom majú tendenciu míňať viac peňazí ročne.

Medzi premennými Čas strávený na aplikácii a Ročné výdavky zákazníka je stredne silne pozitívna korelácia (0.499). Znamená to, že čím viac času strávi zákazník na aplikácii, tým viac peňazí pravdepodobne minie.

Medzi Priemerným časom relácie a Ročnými výdavky zákazníka je stredne silne pozitívna korelácia (0.355). To naznačujú, dĺžka jednej relácie je mierne pozitívne spojená s výdavkami zákazníka.

3. Odhad lineárneho regresného modelu vystihujúceho závislosť Y od $X_1, X_2, \dots, X_k$

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	-1051.59426	22.99254	-45.74	<.0001
Dlžka_clenstva	1	61.57732	0.44834	137.35	<.0001
Priemerny_cas_relacie	1	25.73427	0.45103	57.06	<.0001
Cas_straveny_na_aplikacii	1	38.70915	0.45101	85.83	<.0001
Cas_straveny_na_webstranke	1	0.43674	0.44409	0.98	0.3259

Vysvetľovanou premennou sú Ročné výdavky a vysvetľujúce premenné sú: Dĺžka členstva, Priemerný čas relácie, Čas strávený na aplikácii, Čas strávený na webstránke.

Interpretujeme vyrovnanú nadrovinu

$$\hat{y}_i = -1051.5942 + 61.5773 \cdot x_1 + 25.7342 \cdot x_2 + 38.7091 \cdot x_3 + 0.4367 \cdot x_4$$

Lokujúca konštanta $b_0 = -1051.5942$ predstavuje priemernú hodnotu ročných výdavkov zákazníka, za predpokladu, že všetky štyri vysvetľujúce premenné nadobúdajú nulovú hodnotu. Keďže nie je reálne aby dĺžka členstva, priemerný čas relácie, čas strávený na aplikácii a čas strávený na webstránke boli nulové, lokujúca konštanta v tomto modeli nemá logickú interpretáciu.

Regresný koeficient $b_1 = 61.5773$: Za každý jeden ďalší rok členstva sa ročné výdavky zákazníka zvýšia v priemere o 61.57 dolárov, za predpokladu, že ostatné premenné zostanú konštantné.

Regresný koeficient $b_2 = 25.7342$: Za každú jednu minútu priemerného času relácie sa ročné výdavky zvýšia o 25.73 dolárov, za predpokladu ceteris paribus.

Regresný koeficient $b_3 = 38.7091$: Za každú jednu minútu strávenú na aplikácii sa ročné výdavky zvýšia o 38.71 dolárov, za predpokladu ceteris paribus.

Regresný koeficient $b_4 = 0.43674$: za každú minútu strávenú na webstránke sa ročné výdavky zvýšia iba o 0.44 dolárov, za predpokladu ceteris paribus.

4. Overenie štatistickej významnosti regresného modelu.

Na hladine významnosti 0.05 overujeme štatistickú významnosť regresného modelu

$$\hat{y}_i = -1051.5942 + 61.5773 \cdot x_1 + 25.7342 \cdot x_2 + 38.7091 \cdot x_3 + 0.4367 \cdot x_4$$

$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$ (regresný model nie je štatisticky významný)

$H_1: \exists \beta_i \neq 0$ pre $i \in \{1, 2, 3, 4\}$ (regresný model je štatisticky významný)

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	4	3089891	772473	7766.22	<.0001
Error	495	49236	99.46568		
Corrected Total	499	3139126			

Testovacia charakteristika $F = 7766.22$. je väčšia ako kritická hodnota

$F_{1-\alpha}(k; n - k - 1) = F_{0.95}(4; 495) = 2.39$, čiže nulovú hypotézu o nevýznamnosti regresného modelu zamietame. Na overenie štatistickej významnosti môžeme použiť aj p-hodnotu. Pretože je $p < 0.001$ je menšia ako hladina významnosti 0.05, tak nulovú hypotézu zamietame.

Na hladine významnosti 0.05 je regresný model štatisticky významný, respektíve aspoň jedna z vysvetľujúcich premenných významne ovplyvňuje ročné výdavky zákazníka.

5. Overenie prínosu premennej s najnižším prínosom.

Na hladine významnosti 0.05 overujeme štatistickú významnosť prínosu premennej čas strávený na webstránke na vysvetlenie variability ročných výdavkov zákazníka.

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Type I SS	Type II SS
Intercept	1	-1051.59426	22.99254	-45.74	<.0001	124657254	208063
Dlžka_clenstva	1	61.57732	0.44834	137.35	<.0001	2054923	1876320
Priemerny_cas_relacie	1	25.73427	0.45103	57.06	<.0001	295668	323812
Cas_straveny_na_aplikacii	1	38.70915	0.45101	85.83	<.0001	739204	732713
Cas_straveny_na_webstranke	1	0.43674	0.44409	0.98	0.3259	96.19834	96.19834

H_0 : dodatočný prínos premennej Čas strávený na webstránke k vysvetleniu variability závisle premennej nie je štatisticky významný.

H_1 : dodatočný prínos premennej Čas strávený na webstránke k vysvetleniu variability závisle premennej je štatisticky významný.

V stĺpci *Type I SS* sú riadkoch vyčíslené dodatočné prínosy jednotlivých vysvetľujúcich premenných za predpokladu, že v modeli sa už uvažovalo s premennými, ktoré sú v predchádzajúcich riadkoch.

V stĺpci *Type II SS* sú riadkoch vyčíslené prírastky vysvetlenej variability premennej Y v dôsledku pridania príslušnej premennej do modelu, ktorý už obsahoval všetky ďalšie vysvetľujúce premenné.

Testovacia charakteristika $F = \frac{\Delta \text{var}}{MSR} = \frac{96.19834}{99.46568} = 0.9671$ je menšia ako kritická hodnota $F_{1-\alpha}(1; n - k - 1) = F_{0.95}(1; 495) = 3.86$, čiže nulovú hypotézu nezamietame.

A pretože je $p = 0.3259$ je menšia ako hladina významnosti 0.05, tak nulovú hypotézu nezamietame.

Za predpokladu, že sa už prv uvažovalo s premennými Dĺžka členstva, Priemerný čas relácie, čas strávený na aplikácii, je dodatočný prínos premennej Čas strávený na webstránke k vysvetleniu variability ročných výdavkov zákazníkov na hladine významnosti štatisticky nevýznamný, preto premennú z modelu odstránime.

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	-1035.33958	15.98285	-64.78	<.0001
Dlзка_clenstva	1	61.55603	0.44780	137.46	<.0001
Priemerny_cas_relacie	1	25.72103	0.45081	57.06	<.0001
Cas_straveny_na_aplikacii	1	38.74598	0.44943	86.21	<.0001

Vyrovňavacia nadrovinu po odstránení premennej Čas strávený na webstránke:

$$\hat{y}_i = -1035.3395 + 61.556 \cdot x_1 + 25.721 \cdot x_2 + 38.7459 \cdot x_3$$

6. Výpočet kovariančnej matice S_b

Covariance of Estimates				
Variable	Intercept	Dlžka_clenstva	Priemerny_cas_relacie	Cas_straveny_na_aplikacii
Intercept	255.45153895	-0.225877118	-6.746227419	-2.611090126
Dlžka_clenstva	-0.225877118	0.2005236045	-0.012336008	-0.006216215
Priemerny_cas_relacie	-6.746227419	-0.012336008	0.2032304886	0.0060070221
Cas_straveny_na_aplikacii	-2.611090126	-0.006216215	0.0060070221	0.2019917907

Kovariančná matica obsahuje na diagonále rozptyly odhadnutých parametrov regresného modelu.

7. Overenie štatistickej významnosti regresných koeficientov.

Na hladine významnosti 0.05 overujeme štatistickú významnosť regresných koeficientov.

$$\hat{y}_i = -1035.3395 + 61.556 \cdot x_1 + 25.721 \cdot x_2 + 38.7459 \cdot x_3$$

$$H_0: \beta_1 = 0 \text{ resp. } \beta_2 = 0 \text{ a } \beta_3 = 0$$

$$H_0: \beta_1 \neq 0 \text{ resp. } \beta_2 \neq 0 \text{ a } \beta_3 \neq 0$$

$S_{b0} = 15.9828$, $S_{b1} = 0.4478$, $S_{b2} = 0.4508$, $S_{b3} = 0.4494$ sme vypočítali z kovariančnej matice. Hodnoty testovacích charakteristík sme vypočítali zo vzťahu $t = \frac{b_j}{s_{b_j}}$ a teda

$$t_1 = 137.4631, t_2 = 57.0563, t_3 = 86.217.$$

Kritická hodnota $t_{1-\alpha/2} = t_{0.975}(496) = 1.965$. Absolutné hodnoty testovacích charakteristík pre t_1 , t_2 , t_3 je väčšia ako kritická hodnota, nulové hypotézy zamietame pre β_1 , β_2 , β_3 .

Na hladine významnosti 0.05 regresné koeficienty β_1 , β_2 , β_3 sú štatisticky významné, čiže premenné Dĺžka členstva, Priemerný čas relácie a čas strávený na aplikácii významne ovplyvňujú ročné výdavky zákazníkov.

8. Test zhody regresného koeficienta so zvolenou konštantou.

Na hladine významnosti 0.05 overte, či za podmienky ceteris paribus platí, že zákazník, ktorý má dĺžku členstva predĺženú o 1 rok, zvýši svoje ročné výdavky v priemere o 61 dolárov? A ak zákazník strávi v aplikácii o 10 minút viac, jeho ročné výdavky vzrastú v priemere o 380 dolárov?

$$H_0: \beta_1 = 61 \text{ a } H_0: \beta_3 = 38$$

$$H_1: \beta_1 \neq 61 \text{ a } H_1: \beta_3 \neq 38$$

Test 1 Results for Dependent Variable Rocne_vydavky				
Source	DF	Mean Square	F Value	Pr > F
Numerator	1	153.34937	1.54	0.2149
Denominator	496	99.45909		

Test 2 Results for Dependent Variable Rocne_vydavky				
Source	DF	Mean Square	F Value	Pr > F
Numerator	1	274.00976	2.75	0.0976
Denominator	496	99.45909		

$$\text{Testovacia štatistika: } t = \frac{b_1 - \beta_1}{s_{b1}} = \frac{61.556 - 61}{0.4478} = 1.2416 \text{ a } t = \frac{b_3 - \beta_3}{s_{b3}} = \frac{38.7459 - 38}{0.4494} = 1.6597$$

$$\text{Kritická hodnota: } t_{1-\alpha/2} = t_{0.975}(496) = 1.965$$

V oboch prípadoch je testovacia štatistika menšia než kritická hodnota. Nulovú hypotézu teda nezamietame.

P hodnota 0.2149 a 0.0976 je väčšia ako hladina významnosti 0.05, a teda nulovú hypotézu taktiež nezamietame.

Na hladine významnosti 0.05 môžeme za podmienky ceteris paribus predpokladať, že zvýšením dĺžky členstva o 1 rok vzrastie ročný výdavok zákazníka v priemere o 61 dolárov a takisto môžeme predpokladať, že so zvýšením času stráveného v aplikácii o 10 minút spôsobuje nárast ročných výdavkov zákazníka v priemere o 38 dolárov.

9. Simultánny test pre regresné koeficienty (vlastná voľba konštánt).

Môžeme na hladine významnosti 0.05 tvrdiť, že pri nezmenenom priemernom čase relácie platí, že s nárastom dĺžky členstva zákazníka o 1 rok vzrastú jeho ročné výdavky v priemere o 61 dolárov a súčasne, že s nárastom času stráveného v aplikácii o 10 minút vzrastú jeho ročné výdavky v priemere o 38 dolárov?

$$H_0: \begin{pmatrix} \beta_1 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} 61 \\ 38 \end{pmatrix}$$

$$H_1: \text{non } H_0$$

Test 1 Results for Dependent Variable Rocne_vydavky				
Source	DF	Mean Square	F Value	Pr > F
Numerator	2	220.22107	2.21	0.1103
Denominator	496	99.45909		

Keďže hodnota $F = 2.14$ nie je väčšia ako kritická hodnota $F_{1-\alpha}(s; n - k - 1) = F_{0.95}(2; 496) = 3.0139$, potom nezamietame nulovú hypotézu.

Na základe p-hodnoty ($p = 0.1103$) nulovú hypotézu nezamietame, pretože je väčšia ako hladina významnosti 0.05.

Na základe simultánneho testovania hypotéz $H_0: \beta_1 = 61$ a $H_0: \beta_3 = 38$ na hladine významnosti 0.05 môžeme predpokladať, že platia súčasne obidve hypotézy.

10. Intervaly spoľahlivosti pre regresné koeficienty.

So spoľahlivosťou 0.95 sme odhadli regresné koeficienty nadroviny vystihujúce závislosť ročných výdavkov zákazníka od dĺžky členstva, priemerného času relácie a času stráveného na aplikácii.

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	95% Confidence Limits	
Intercept	1	-1035.33958	15.98285	-64.78	<.0001	-1066.74202	-1003.93714
Dlžka_clenstva	1	61.55603	0.44780	137.46	<.0001	60.67622	62.43585
Priemerny_cas_relacie	1	25.72103	0.45081	57.06	<.0001	24.83530	26.60677
Cas_straveny_na_aplikacii	1	38.74598	0.44943	86.21	<.0001	37.86295	39.62901

$$P(60.68 < \beta_1 < 62.44) = 0.95$$

$$P(24.84 < \beta_2 < 26.61) = 0.95$$

$$P(37.86 < \beta_3 < 39.63) = 0.95$$

S 95% pravdepodobnosťou zvýšením dĺžky členstva o 1 rok spôsobí zvýšenie výdavkov zákazníka v priemere o viac ako 60.68 dolárov a súčasne o menej ako 62.44dolárov, za predpokladu ceteris paribus.

S 95% pravdepodobnosťou zvýšením priemerného času relácie o 1 minútu spôsobí zvýšenie výdavkov zákazníka v priemere o viac ako 24.84 dolárov a súčasne o menej ako 26.61 dolárov, za predpokladu ceteris paribus.

Zvýšením času stráveného na aplikácii o 1 minútu spôsobí zvýšenie výdavkov zákazníka v priemere o viac ako 37.86 dolárov a súčasne o menej ako 39.63 dolárov, za predpokladu ceteris paribus.

11. Intervaly spoľahlivosti pre strednú a individuálnu hodnotu vysvetľovanej premennej pre zvolený vektor hodnôt vysvetľujúcich premenných.

So spoľahlivosťou 0.95 sme odhadli,

- a.) Priemernú sumu výdavkov zákazníka s dĺžkou členstva 2 roky, priemerným časom relácie 35 minút a časom stráveným na aplikácii 15minút.
- b.) výšku výdavkov zákazníka s dĺžkou členstva 2 roky, priemerným časom relácie 35 minút a časom stráveným na aplikácii 15minút.

Rocne_vydavky	predicted_Rocne_vydavky	lcl_Rocne_vydavky	lclm_Rocne_vydavky	ucl_Rocne_vydavky	uclm_Rocne_vydavky
497.77864222	481.415	461.775	480.078	501.055	482.751
.	569.198	549.272	565.579	589.124	572.818

1.stĺpec: pozorované hodnoty vysvetľovanej premennej

2. stĺpec: vyrovnané hodnoty (bodový odhad)

3. stĺpec: lcl- lower confidence limit

4. stĺpec: lclm – lower confidence for mean

5. stĺpec: ucl – upper confidence limit

6. stĺpec: uclm – upper confidence for mean

Hranice intervalov spoľahlivosti pre strednú hodnotu závisle premennej určíme podľa dolnej hranice - lclm a hornej hranice – uclm.

Hranice intervalov spoľahlivosti pre individuálnu hodnotu závisle premennej určíme podľa dolnej hranice - lcl a hornej hranice – ucl.

- a.) So spoľahlivosťou 0.95 je priemerná suma výdavkov zákazníka s dĺžkou členstva 2 roky, priemerným časom relácie 35 minút a časom stráveným na aplikácii 15minút vyššia ako 565.579 dolárov a súčasne nižšia ako 572.818 dolárov.
- b.) So spoľahlivosťou 0.95 je suma výdavkov zákazníka s dĺžkou členstva 2 roky, priemerným časom relácie 35 minút a časom stráveným na aplikácii 15minút vyššia ako 549.272 dolárov a súčasne nižšia ako 589.124 dolárov.


12. Mnohonásobný koeficient determinácie, parciálne koeficienty determinácie a parciálne koeficienty korelácie (odhad a overenie ich významnosti).

Root MSE	9.97292	R-Square	0.9843
Dependent Mean	499.31404	Adj R-Sq	0.9842
Coeff Var	1.99732		

Výberový koeficient determinácie: $r^2_{y,123} = 0.9843$

Korigovaný koeficient determinácie: $r^2_{y,123(adj)} = 0.9842$

Bodovým odhadom viacnásobného koeficienta determinácie $\rho^2_{y,123}$ je výberová viacnásobný koeficient determinácie $r^2_{y,123} = 0.9843$.



Graf skutočných hodnôt vysvetľovanej premennej vzhľadom na hodnoty regresnej funkcie (predikované hodnoty) charakterizuje intenzitu a tesnosť lineárnej závislosti.

Skutočné a predikované hodnoty sú koncentrované okolo priamky čo naznačuje vysokú presnosť modelu a tesnú lineárnu závislosť.

Výberový viacnásobný koeficient determinácie $r^2_{y,123} = 0.9843$: Lineárnou regresnou funkciou

$$\hat{y}_i = -1035.3395 + 61.556 \cdot x_1 + 25.721 \cdot x_2 + 38.7459 \cdot x_3$$

S vysvetľujúcimi premennými Dĺžka členstva, Priemerný čas relácie a Čas strávený na aplikácii vieme vyjadriť variabilitu Ročné výdavky na 98.43%. Zvyšných 1.57% variability ročných výdavkov zákazníka spôsobujú činitele nezahrnuté do regresného modelu ako napríklad sezónne vplyvy, vek zákazníka, inflácia atď. a náhodné vplyvy.

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Squared Partial Corr Type I	Squared Partial Corr Type II
Intercept	1	-1035.33958	15.98285	-64.78	<.0001	.	.
Dlžka_clenstva	1	61.55603	0.44780	137.46	<.0001	0.65462	0.97442
Priemerny_cas_relacie	1	25.72103	0.45081	57.06	<.0001	0.27271	0.86778
Cas_straveny_na_aplikacii	1	38.74598	0.44943	86.21	<.0001	0.93744	0.93744

Interpretácia parciálnych koeficientov determinácie typu I:

- $r^2_{y1} = 65.46$: Ak by bola zaradená prvá premenná Dĺžka členstva , vysvetlila by 65.46% variability premennej Ročné výdavky.
- $r^2_{y2.1} = 27.27$: Ak by bola do modelu zaradená ako druhá premenná Priemerný čas relácie, vysvetlila by 27.27% z tej variability premennej Ročné výdavky, ktorá nebola vysvetlená premennou Dĺžka členstva. Dodatočný prínos premennej Priemerný čas relácie je $((1-0.6546)*0.2727 = 0.0942)$ je 9.42%
 - Ak by v regresnom modeli boli uvažované len dve vysvetľované premenné a to Dĺžka členstva a Priemerný čas relácie, tak výberový koeficient determinácie by mal hodnotu $r^2_{y,12}=0.7488$. Prvé dve premenné vysvetľujú 74.88% variability premennej Ročné výdavky a ostáva nevysvetlených $((1-0.7488)*100\%)$ 25.12%.
- $r^2_{y3.12} = 93.74$: Ak by do modelu ako tretia bola zaradená premenná Čas strávený na aplikácii, vysvetlila by 93.74% z tej variability premennej Ročné výdavky, ktorá nebola vysvetlená premennou Ročné výdavky a Priemerný čas relácie. Dodatočný prínos premennej čas strávený na aplikácii je $((1-(0.6546 + 0.0942))*0.9374=0.2355)$ je 23.55%.

Premenné Dĺžka členstva, Priemerný čas relácie Čas strávený na aplikácii postupne v tomto poradí vysvetľujú 65.46%, 9.42% a 23.55%. k vysvetleniu variability premennej ročné výdavky zákazníka a spolu vysvetľujú 93.43%.

2 Partial Variables:	Priemerny_cas_relacie Cas_straveny_na_aplikacii
1 With Variables:	Dlзка_clenstva
1 Variables:	Rocne_vydavky

Pearson Partial Correlation Coefficients, N = 500 Prob > r under H0: Partial Rho=0	
	Rocne_vydavky
Dlзка_clenstva	0.98713 <.0001

$H_0: \rho_{y1.23} = 0$ (parciálny koeficient nie je štatisticky významný)

$H_1: \rho_{y1.23} \neq 0$ (parciálny koeficient je štatisticky významný)

Vypočítaná hodnota $p < .0001$ je menšia ako hladina významnosti 0.05. Nulovú hypotézu o štatistickej nevýznamnosti zamietame.

Parciálny koeficient korelácie $r_{y1.23}=0.98713$. Medzi ročnými výdavkami a dĺžkou členstva je za predpokladu nemenného priemerného času relácie a času stráveného na aplikácii silá priama lineárna závislosť. Na hladine významnosti 0.05 dĺžka členstva významne ovplyvňuje ročné výdavky, pri eliminácii priemerného času relácie a času strávenom na aplikácii.

2 Partial Variables:	Dlзка_clenstva Cas_straveny_na_aplikacii
1 With Variables:	Priemerny_cas_relacie
1 Variables:	Rocne_vydavky

Pearson Partial Correlation Coefficients, N = 500 Prob > r under H0: Partial Rho=0	
	Rocne_vydavky
Priemerny_cas_relacie	0.93155 <.0001

$H_0: \rho_{y2.13} = 0$

$H_1: \rho_{y2.13} \neq 0$

Vypočítaná hodnota $p < .0001$ je menšia ako hladina významnosti 0.05. Nulovú hypotézu o štatistickej nevýznamnosti zamietame.

Parciálny koeficient korelácie $r_{y2.13}=0.93155$. Medzi ročnými výdavkami a priemerným časom relácie je za predpokladu nemennej dĺžky členstva a času stráveného na aplikácii silá priama lineárna závislosť. Na hladine významnosti 0.05 priemerný čas relácie významne ovplyvňuje ročné výdavky, pri eliminácii dĺžky členstva a času strávenom na aplikácii.

2 Partial Variables:	Dlžka_clenstva	Priemerny_cas_relacie
1 With Variables:	Cas_straveny_na_aplikacii	
1 Variables:	Rocne_vydavky	

Pearson Partial Correlation Coefficients, N = 500 Prob > r under H0: Partial Rho=0	
	Rocne_vydavky
Cas_straveny_na_aplikacii	0.96821 <.0001

$$H_0: \rho_{y3.12} = 0$$

$$H_1: \rho_{y3.12} \neq 0$$

Vypočítaná hodnota $p < .0001$ je menšia ako hladina významnosti 0.05. Nulovú hypotézu o štatistickej nevýznamnosti zamietame.

Parciálny koeficient korelácie $r_{y3.12}=0.96821$. Medzi ročnými výdavkami a časom stráveným na aplikácii je za predpokladu nemennej dĺžky členstva a priemerného času relácie silá priama lineárna závislosť. Na hladine významnosti 0.05 čas strávený na aplikácii významne ovplyvňuje ročné výdavky, pri eliminácii dĺžky členstva a priemerný čas strávený na aplikácii.

13. Test zhody parciálneho koeficienta korelácie so zvolenou konštantou.

Na hladine významnosti 0.025 overujeme, či intenzita lineárnej závislosti medzi ročnými výdavkami a časom stráveným na aplikácii pri eliminácii dĺžky členstva a priemerný čas strávený na aplikácii je slabšia ako 0.25.

$$H_0: \rho_{y3.12} = 0.25$$

$$H_1: \rho_{y3.12} < 0.25$$

Pearson Partial Correlation Statistics (Fisher's z Transformation)				
Variable	With Variable	Upper 97.5% CL	H0: Partial Rho>=Rho0	
			Rho0	p Value
Rocne_vydavky	Cas_straveny_na_aplikacii	0.973229	0.25000	1.0000

$$P(\rho_{y3.12} < 0.973229) = 0.975$$

Na hladine významnosti 0.025 môžeme predpokladať, že intenzita lineárnej závislosti medzi premennými ročné výdavky a čas strávený na aplikácii pri eliminácii dĺžky členstva a priemerného času stráveného na aplikácii je slabšia ako 0.25.

14. Interval spoľahlivosti pre vybraný parciálny koeficient korelácie.

So spoľahlivosťou 0.95 odhadneme intenzitu lineárnej závislosti medzi ročnými výdavkami a časom stráveným na aplikácii pri eliminácii dĺžky členstva a priemerný čas strávený na aplikácii a na základe tohto odhadu overujeme štatistickú významnosť predmetnej závislosti.

Pearson Partial Correlation Statistics (Fisher's z Transformation)							
Variable	With Variable	N	N Partialled	Sample Correlation	Fisher's z	Bias Adjustment	Correlation Estimate
Rocne_vydavky	Cas_straveny_na_aplikacii	500	2	0.96821	2.06293	0.0009741	0.96815

Pearson Partial Correlation Statistics (Fisher's z Transformation)					
Variable	With Variable	95% Confidence Limits		H0: Partial Rho=Rho0	
				Rho0	p Value
Rocne_vydavky	Cas_straveny_na_aplikacii	0.962134	0.973229	0	<.0001

$$P(0.962134 < \rho_{y3.12} < 0.973229) = 0.975$$

S pravdepodobnosťou 0.95 je medzi ročnými výdavkami a časom stráveným na aplikácii pri eliminácii dĺžky členstva a priemerný čas strávený na aplikácii priama silná lineárna závislosť, ktorá je silnejšia ako 0.962134 a súčasne slabšia ako 0.973229. S rizikom 5% je parciálny koeficient korelácie rôzny od nuly a skúmaná závislosť je štatisticky významná.

15. Diagnostikovanie multikolinearity. Testovanie multikolinearity Farrar-Glauberovým testom (uviesť výstup s korelačnou maticou). Posúdenie stupňa multikolinearity s využitím charakteristík: *VIF*, index podmienenosti a príp. iných x R

Pearson Correlation Coefficients, N = 500 Prob > r under H0: Rho=0				
	Rocne_vydavky	Dlзка_clenstva	Priemerny_cas_relacie	Cas_straveny_na_aplikacii
Rocne_vydavky	1.00000 <.0001	0.80908 <.0001	0.35509 <.0001	0.49933 <.0001
Dlзка_clenstva	0.80908 <.0001	1.00000	0.06025 0.1786	0.02914 0.5156
Priemerny_cas_relacie	0.35509 <.0001	0.06025 0.1786	1.00000	-0.02783 0.5348
Cas_straveny_na_aplikacii	0.49933 <.0001	0.02914 0.5156	-0.02783 0.5348	1.00000

$$R_x = \begin{bmatrix} 1,00000 & 0,06025 & 0,02914 \\ 0,06025 & 1,00000 & -0,02783 \\ 0,02914 & -0,02783 & 1,00000 \end{bmatrix}$$

$$|R_x| = 0,994649$$

Determinant výberovej korelačnej matice vysvetľujúcich premenných naznačuje slabú multikolinearitu.

Farrar – Glaubenov test:

$$H_0: \rho_x = I_k(\text{medzi premennými nie je multikolinearita})$$

$$H_1: \rho_x \neq I_k(\text{medzi premennými je multikolinearita})$$

$$\chi^2 = - \left[n - 1 - \frac{2k}{6} \right] \ln |R_x| = - \left[500 - 1 - \frac{2 * 3 + 5}{6} \right] \ln 0,994649 = 2.668$$

$$\chi^2 > \chi^2_{1-\alpha} \left[\frac{1}{2} k (k - 1) \right] = \chi^2_{0.95}(3) = 7.815$$

Hodnota testovacej štatistiky je menšia než kritická hodnota, preto na hladine významnosti 0.05 nezamietame nulovú hypotézu. Medzi premennými nie je významná multikolinearita.

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Tolerance	Variance Inflation
Intercept	1	-1035.33958	15.98285	-64.78	<.0001	.	0
Dlžka_clenstva	1	61.55603	0.44780	137.46	<.0001	0.99542	1.00460
Priemerny_cas_relacie	1	25.72103	0.45081	57.06	<.0001	0.99549	1.00453
Cas_straveny_na_aplikacii	1	38.74598	0.44943	86.21	<.0001	0.99827	1.00173

Collinearity Diagnostics						
Number	Eigenvalue	Condition Index	Proportion of Variation			
			Intercept	Dlžka_clenstva	Priemerny_cas_relacie	Cas_straveny_na_aplikacii
1	3.93862	1.00000	0.00004994	0.00454	0.00005739	0.00043051
2	0.05626	8.36689	0.00107	0.98939	0.00119	0.01095
3	0.00469	28.96835	0.02199	0.00592	0.04074	0.93750
4	0.00042874	95.84620	0.97690	0.00014373	0.95801	0.05113

- Stĺpec Tolerance – výberový koeficient neurčitosti $1 - r_j^2$
- Variance Inflation – VIF_j obrátená hodnota výberového koeficientu neurčitosti
- Eigenvalue – vlastné čísla
- Condition Index – indexy podmienenosti

Charakteristika VIF_j v prípade žiadnej vysvetľujúcej premennej neprekračuje hodnotu 10, ktorá by signalizovala silnú multikolinearitu. Najvyššia hodnota indexu podmienenosti je 95.84620 je v rozpätí 30 až 100, čo hovorí o strednom stupni multikolinearity, avšak ostatné indikátory sú nízke, čo zmierňuje tento efekt. Hodnota 0.95801 v Proportion of Variation ukazuje, že multikolinearitu spôsobuje premenná priemerný čas relácie čo nekorešponduje s ostatnými charakteristikami.

16. Diagnostikovanie extrémnych a vplyvných pozorovaní.

Referenčná hodnota pre $\text{DIFFT}_{(-i)}$: $2\sqrt{\frac{p}{n}} = 2\sqrt{\frac{4}{500}} = 0.178854$

Vplyvné pozorovania sú tie ktoré nepatria do intervalu $<-0.1788, 0.1788>$. V našom súbore je 23 pozorovaní ktoré nepatria do daného intervalu a 477 pozorovaní ktoré patria do intervalu. Identifikovali sme 23 vplyvných pozorovaní.

Cookova Štatistika: referenčná hodnota $\frac{4}{n} = \frac{4}{500} = 0.008$


Kritérium $D_i > 0.008$ spĺňa 23 pozorovaní. Podľa $\text{DIFFT}_{(-i)}$ Cookovej štatistiky sme odhalili 23 vplyvných pozorovaní.

Najvyššie absolútne hodnoty charakteristiky $\text{DIFFT}_{(-i)}$:


$[\text{DIFFT}_{(-i)}=0.40851, \text{DIFFT}_{(-i)}=0.3411]$ a súčasne najvyššie hodnoty Cookovej štatistiky:

$[D_i = 0.0411, D_i = 0.0289]$. Pozorovania v prípade $\text{DIFFT}_{(-i)}$ prekračujú referenčnú hodnotu približne 2-násobne a v prípade Cookovej štatistiky prekračujú referenčnú hodnotu viac ako 5-násobne.



dfits_Rocne_vydavky	cookd_Rocne_vydavky
-0.408510699	0.007903219
-0.267766797	0.0083880249
-0.242347315	0.0084726701
-0.239189419	0.0087744742
-0.229983059	0.0090599065
-0.229055348	0.0093653863
-0.226544098	0.0093851234
-0.217425341	0.0095444107
-0.195848498	0.010110038
-0.188038577	0.0112097435
-0.174214416	0.0116730075
	0.0128152725
	0.0130556409
0.1780864755	0.0131102719
0.183706894	0.013198455
0.1843684926	0.0141874515
0.1909789326	0.014586783
0.193785676	0.0154807844
0.1938268453	0.0169527163
0.2018702895	0.0178512963
0.2122370672	0.0185123486
0.2304374857	0.020834813
0.2494785642	0.0289948713
0.261400931	0.0411895094
0.2743481283	
0.2911168307	
0.3413228474	



($DFFITS_{(i)}$) Referenčné hodnoty $-0.1788, 0.1788$ na grafe sú znázornené na grafe v podobe horizontálnych priamok.




(Cookova štatistika) Referenčná hodnoty 0.008 na grafe je znázornená na grafe v podobe horizontálnej priamky.



Referenčná hodnota 0.178854 je v grafe v podobe vertikálnej priamky.


Na základe charakteristík sme odhalili 23 vplyvných pozorovaní, ktoré majú výrazný vplyv na predikované hodnoty. Zvýšenú pozornosť by sme mali venovať pozorovaniu ktoré podľa oboch štatistík bolo diagnostikované ako najvplyvnejšie s hodnotou DIFFIT = 0.02208 a Cookova štatistika 0.41189.

17. Overenie predpokladov o náhodnej zložke na základe grafickej analýzy.




Graf jackknife reziduí (Rstudent) vzhľadom na vyrovnané hodnoty vysvetľovanej premennej

Väčšina bodov sa nachádza v rozmedzí $(-2,2)$, čo naznačuje, že väčšina reziduí je normálna a neobsahuje extrémne hodnoty. Lievikovitý tvar alebo systematický vzor by naznačovali heteroskedasticitu, ale v tomto prípade je variabilita reziduí relatívne konzistentná. Môžeme konštatovať, že predpoklad o nezávislosti chýb je splnený, pretože neexistuje zjavná autokorelácia reziduí.



Histogram reziduí

Rezíduá sa sústreďujú okolo 0 a majú symetrický tvar, čo naznačuje, že rozdelenie rezíduí je blízke normálnemu rozdeleniu. 95,4 % rezíduí je v intervale $(-2,2)$ podľa Grafu jackknife rezíduí, pričom zvyšok sa nachádza mimo tohto rozmedzia. Malé rozdiely na pravom chvoste histogramu naznačujú drobné odchýlky od normality, avšak veľká časť dát kopíruje normálne rozdelenie. Predpoklad o normalite náhodnej zložky je teda prevažne splnený.



Q-Q graf rezíduí

Väčšina bodov leží blízko diagonály, čo naznačuje, že empirické rozdelenie rezíduí dobre kopíruje normálne rozdelenie. Predpoklad o normalite rezíduí je považovaný za splnený.

18. Overenie homoskedasticity náhodnej zložky. HC odhad kovariančnej matice S_b a overenie štatistickej významnosti regresných koeficientov s využitím HC odhadov.

H_0 : regresné koeficienty nie sú štatisticky významné

H_1 : regresné koeficienty sú štatisticky významné

Test of First and Second Moment Specification		
DF	Chi-Square	Pr > ChiSq
9	14.92	0.0931

Whitov test.

Kritická hodnota $\chi^2_{1-\alpha}(9) = 16.919$ na hladine významnosti 0.05

Hodnota testovacej štatistiky 14.92 je menšia ako kritická hodnota 16.919 preto nulovú hypotézu nezamietame. Potvrďuje to aj p-hodnota 0.0931, ktorá je väčšia ako hladina významnosti 0.05. Výsledok Whitovho testu naznačuje, že predpoklad homoskedasticity nie je porušený a teda rozptyl rezíduí je konštantný.

Parameter Estimates								
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Heteroscedasticity Consistent		
						Standard Error	t Value	Pr > t
Intercept	1	-1035.33958	15.98285	-64.78	<.0001	15.87027	-65.24	<.0001
Dlžka_clenstva	1	61.55603	0.44780	137.46	<.0001	0.43053	142.98	<.0001
Priemerny_cas_relacie	1	25.72103	0.45081	57.06	<.0001	0.44079	58.35	<.0001
Cas_straveny_na_aplikacii	1	38.74598	0.44943	86.21	<.0001	0.44271	87.52	<.0001

Heteroscedasticity Consistent Covariance of Estimates				
Variable	Intercept	Dlžka_clenstva	Priemerny_cas_relacie	Cas_straveny_na_aplikacii
Intercept	251.86541894	0.19303639	-6.555868289	-2.988889973
Dlžka_clenstva	0.19303639	0.1853582038	-0.02762678	0.0044535761
Priemerny_cas_relacie	-6.555868289	-0.02762678	0.1942922488	0.0193566987
Cas_straveny_na_aplikacii	-2.988889973	0.0044535761	0.0193566987	0.1959894439

Odhad kovariančnej matice odhadov parametrov regresného modelu.

Na základe p-hodnoty HC odhadov sme zistili, že po zohľadnení heteroskedasticity náhodnej zložky sme na hladine 0.05 zistili, všetky regresné koeficienty sú štatisticky významné. To znamená, že každá vysvetľujúca premenná má významný prínos k vysvetleniu variability závislej premennej.

19. Overenie normality náhodnej zložky

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.998174	Pr < W	0.8794
Kolmogorov-Smirnov	D	0.023448	Pr > D	>0.1500
Cramer-von Mises	W-Sq	0.030568	Pr > W-Sq	>0.2500
Anderson-Darling	A-Sq	0.217331	Pr > A-Sq	>0.2500

Testy normality reziduí pre parametre odhadnuté z výberového súboru.

H_0 : náhodné chyby ε_i majú normálne rozdelenie pravdepodobnosti

H_1 : chyby ε_i nemajú normálne rozdelenie pravdepodobnosti

$$D\left(\sqrt{n} - 0.01 + \frac{0.85}{\sqrt{n}}\right) = 0.0234\left(\sqrt{500} - 0.01 + \frac{0.85}{\sqrt{500}}\right) = 0.5239$$

$$W^2\left(1 + \frac{0.5}{n}\right) = 0.0306\left(1 + \frac{0.5}{500}\right) = 0.036$$

$$A^2\left(1 + \frac{0.75}{n} + \frac{2.25}{n^2}\right) = 0.2173\left(1 + \frac{0.75}{500} + \frac{2.25}{500^2}\right) = 0.2176$$

Pre Shapiro–Wilkov test p-hodnota nadobúda 0.8794 čo je viac ako hladina významnosti 0.05, preto nulovú hypotézu o normálnom rozdelení pre tento test nezamietame. Hodnoty modifikovaných testovacích štatistík nie sú väčšie ako kritické hodnoty 0.895, 0.126 a 0.752, preto na hladine významnosti 0.05 nezamietame nulovú hypotézu o normálnom rozdelení náhodnej zložky. A aj na základe p-hodnôt ostatných testov nezamietame nulovú hypotézu o normalite reziduii.

Parameters for Normal Distribution		
Parameter	Symbol	Estimate
Mean	Mu	-0.00008
Std Dev	Sigma	1.000878

Kvantily normálneho rozdelenia s parametrami $\mu=-0.00008$ a $\sigma^2=1.000878$

Quantiles for Normal Distribution		
Percent	Quantile	
	Observed	Estimated
1.0	-2.51550	-2.32847
5.0	-1.71323	-1.64637
10.0	-1.25995	-1.28275
25.0	-0.64335	-0.67516
50.0	-0.01358	-0.00008

Quantiles for Normal Distribution		
Percent	Quantile	
	Observed	Estimated
75.0	0.64049	0.67501
90.0	1.27848	1.28260
95.0	1.65830	1.64622
99.0	2.27121	2.32831

Empirické a teoretické kvantily normálneho rozdelenia

Empirické kvantily sú veľmi blízke teoretickým kvantilom normálneho rozdelenia, čo naznačuje, že rezíduá dobre zodpovedajú normálnemu rozdeleniu. Menšie odchýlky na chvostoch (1. a 99. percentil) naznačujú o niečo „ťažšie“ chvosty rozdelenia, ale tieto rozdiely nie sú výrazné.

Na hladine významnosti 0.05 môžeme predpokladať, že náhodná zložka má normálne rozdelenie.

20. Overenie nezávislosti chýb (Durbinov-Watsonov test, test štatistickej významnosti koeficienta autokorelácie).

H_0 : chyby ε_i sú nezávislé

H_1 : chyby ε_i sú navzájom závislé (prítomná autokorelácia)

Durbin-Watson D	1.888
Pr < DW	0.1070
Pr > DW	0.8930
Number of Observations	500
1st Order Autocorrelation	0.053

Charakteristiky autokorelácie s p-hodnotami pre Durbinovu-Watsonovu štatistiku

P-hodnota Pr<DW (0.1070) pre jednostranný test s alternatívnou hypotézou $H_1: \rho_1 > 0$ je väčšia ako hladina významnosti 0.05, čiže nulovú hypotézu nezamietame. Na hladine významnosti 0.05 nemôžeme predpokladať pozitívnu autokoreláciu.

P-hodnota Pr>DW (0.8930) pre jednostranný test s alternatívnou hypotézou $H_1: \rho_1 < 0$ je väčšia ako hladina významnosti 0.05, čiže nulovú hypotézu nezamietame. Na hladine významnosti 0.05 nemôžeme predpokladať negatívnu autokoreláciu.

Test štatistickej významnosti 1. stupňa. Výberový necyklický koeficient autokorelácie má hodnotu 0.052, čo je blízke nule a z toho usudzujeme že, koeficient 1. stupňa nie je štatisticky významný.

Na hladine významnosti 0.05 chyby ε_i nie sú autokorelované a predpoklad o nezávislosti náhodných chýb považujeme za splnený.